U03 · Autoencoder y VAE

LAB10 · Evidencias del Ejercicio 06

Victor Manuel Perez Padilla | Matrícula: 100801946

Unidad 03 · Algoritmos y características generativas
Guía docente: Edwin Ramón José Nolasco

Repositorio del proyecto · carpeta generativos

1. Objetivo y estado de la entrega

Comparar compresión y reconstrucción con generación probabilística, examinando fidelidad, diversidad, latente y costo. TensorFlow está aislado del recomendador. El ZIP docente devolvió HTTP 403: se implementó el proyecto siguiendo la guía, sin afirmar que sea la base oficial. Se entregan modelos, notebook ejecutado, pruebas y app de inferencia.

2. Datos y protocolo reproducible

Fashion-MNIST, Zalando Research, licencia MIT: 60,000 imágenes de entrenamiento y 10,000 de prueba, 28×28 en gris. Se separan 50,000 fit y 10,000 validación estratificada, semilla 42; prueba se evalúa tras elegir checkpoints por validación. Normalización float32 / 255. Las etiquetas no condicionan los modelos.

Fuente fijada por commit b2617bb6d3ffa2e429640350f613e3291e10b141. SHA-256 y fechas de los cuatro archivos: reports/download_manifest.json. Aviso MIT conservado; no se redistribuye la descarga completa ni MovieLens.

3. Modelos y tabla principal de resultados

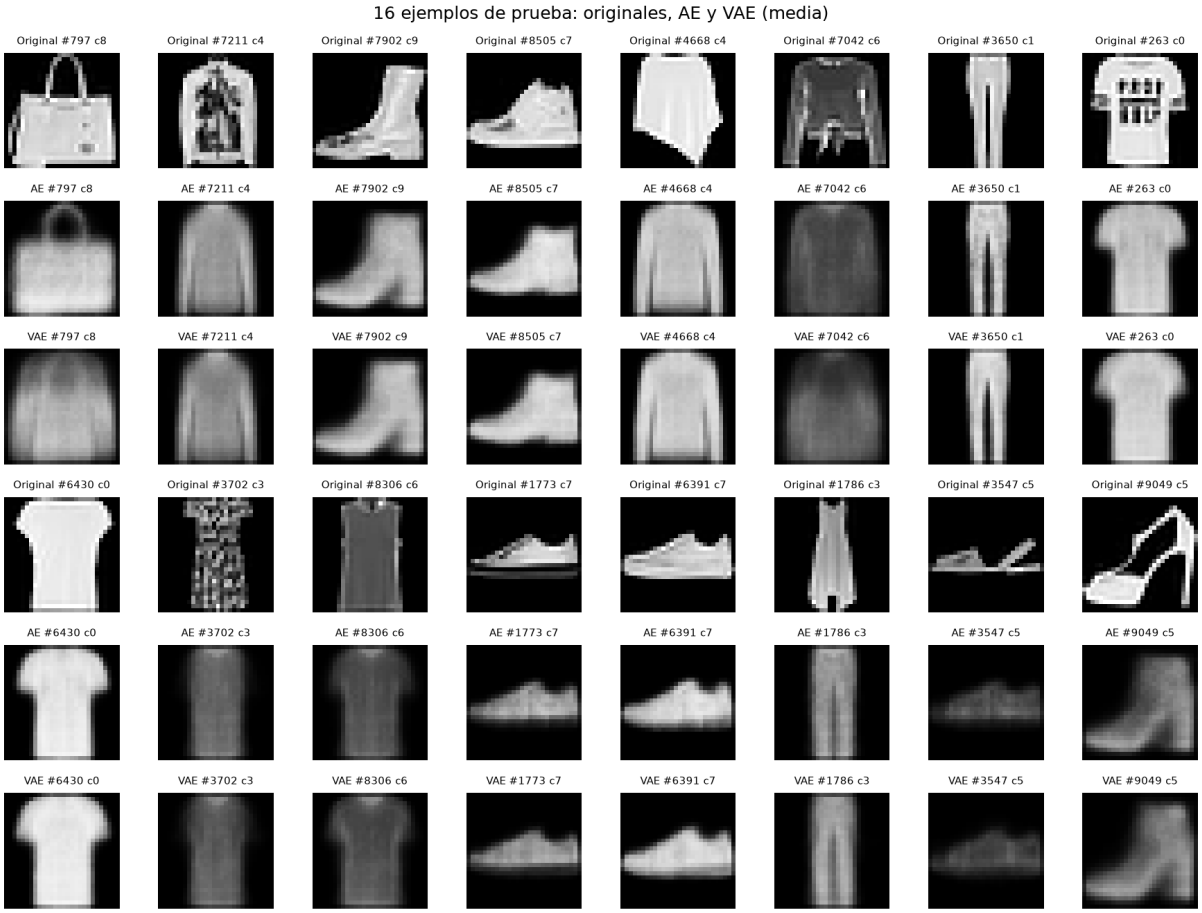
Redes densas 784 → 256 → 128 → latente 2; decoder 128 → 256 → 784 sigmoid. AE minimiza BCE sumada; VAE usa reparametrización y suma KL con beta=1. Adam .001, batch 256. Se restaura la época 6 AE y 8 VAE por menor pérdida de validación.

Modelo	MSE prueba	BCE/píxel	Épocas	Fit (s)	Modelo MB
Imagen media	0.086641	0.491094	0	No medido	0.0031*
AE	0.028717	0.327269	6	7.70	1.922
VAE (media)	0.030226	0.331847	8	9.94	1.926

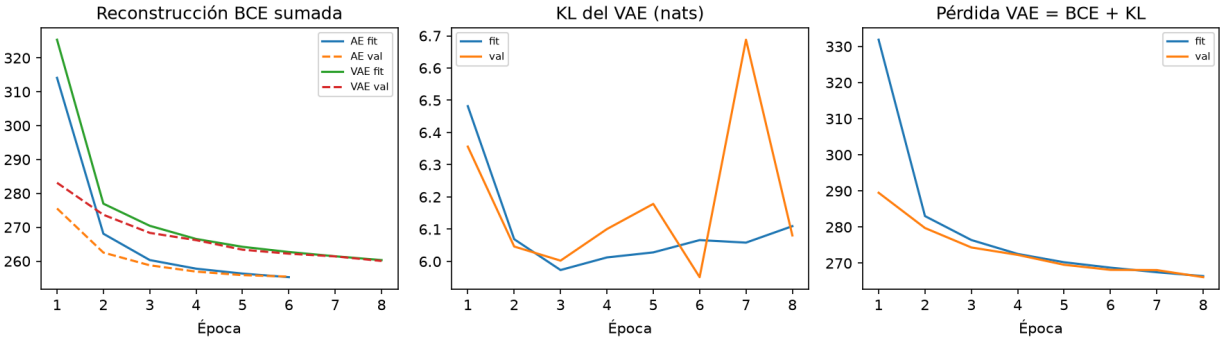
*Baseline: 784 float32 sin contenedor. Otros: tamaño real .keras sin optimizador. CPU, Python 3.12.14, TensorFlow 2.21.0. Tiempo incluye fit, validación y trazado; excluye descarga, figuras y serialización. No se midieron energía ni pico de RAM. Presupuestos de épocas distintos; una semilla de entrenamiento.

4. Reconstrucción: panel no seleccionado

16 ejemplos uniformes sin reemplazo, semilla 2026; índices en panel_indices.json. Cada bloque contiene originales, AE y VAE con media posterior. Los mismos ejemplos se muestran completos, sin escoger los mejores.



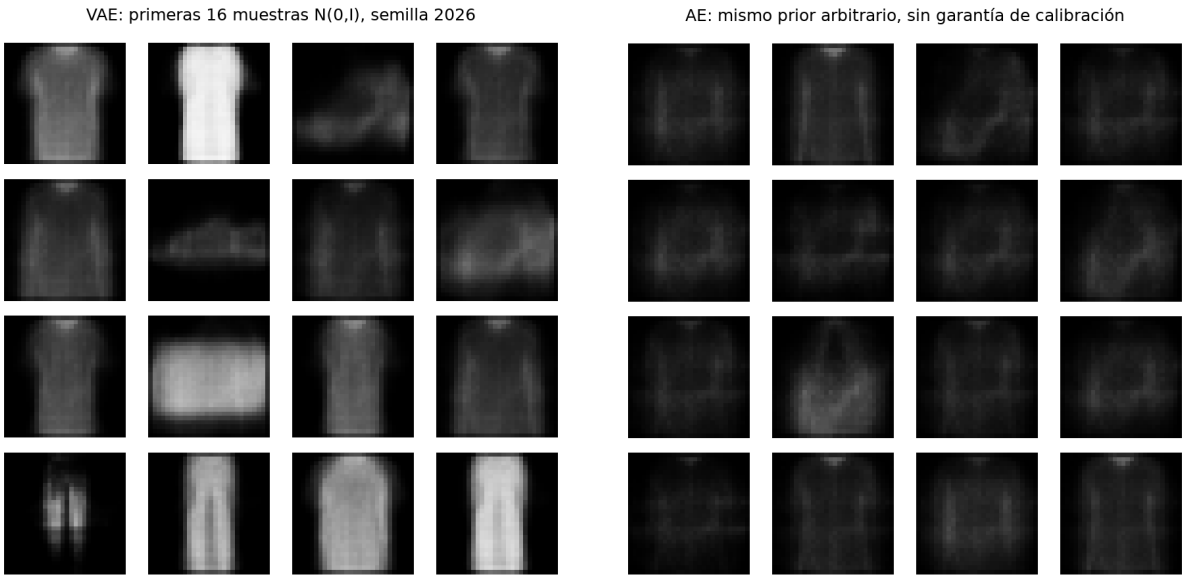
Se pierden estampados de camiseta #263 y detalles del vestido #3702. Las sandalias #3547/#9049 quedan ambiguas y el VAE reconstruye el bolso #797 como prenda superior. Bag tiene mayor MSE: AE .03760 y VAE .05003; Sneaker el menor: .01943 y .01938. No son errores de clasificación.



Las curvas de validación mejoran en el presupuesto probado; no demuestran ausencia de sobreajuste futuro. KL medio de prueba: 6.0725 nats. Además de reconstruir la media, una muestra posterior fija obtiene MSE .030705. Error bajo no prueba capacidad generativa.

5. Muestreo, diversidad y limitaciones

Primeras 16 de 256 muestras N(0,I), semilla 2026. Izquierda: VAE; derecha: AE con el mismo prior arbitrario. El AE no aprendió a ajustar su latente a esa distribución. La comparación no descarta otras estrategias de generación AE.

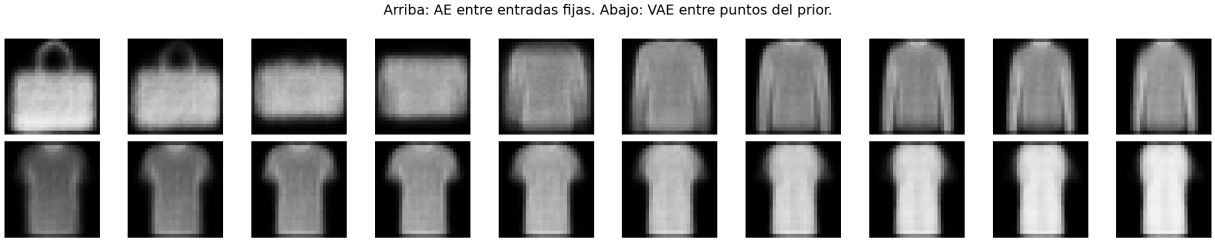


VAE produce prendas superiores, pantalones y calzado, pero con bordes borrosos y formas ambiguas. AE-prior produce salidas oscuras y parecidas. La diversidad numérica no mide realismo ni demuestra cobertura semántica.

Diagnóstico	VAE / AE-prior / referencia
MSE medio entre pares	0.08777 / 0.00628 / 0.21547
Desviación media por píxel	0.19015 / 0.04816 / 0.29231

256 muestras por modelo frente a referencia de solo 16 originales; tamaños distintos. No se calculó FID ni una métrica perceptual validada en este dominio. Clases de vecinos son indicadores indirectos, no etiquetas certificadas de los sintéticos.

6. Interpolación y espacio latente

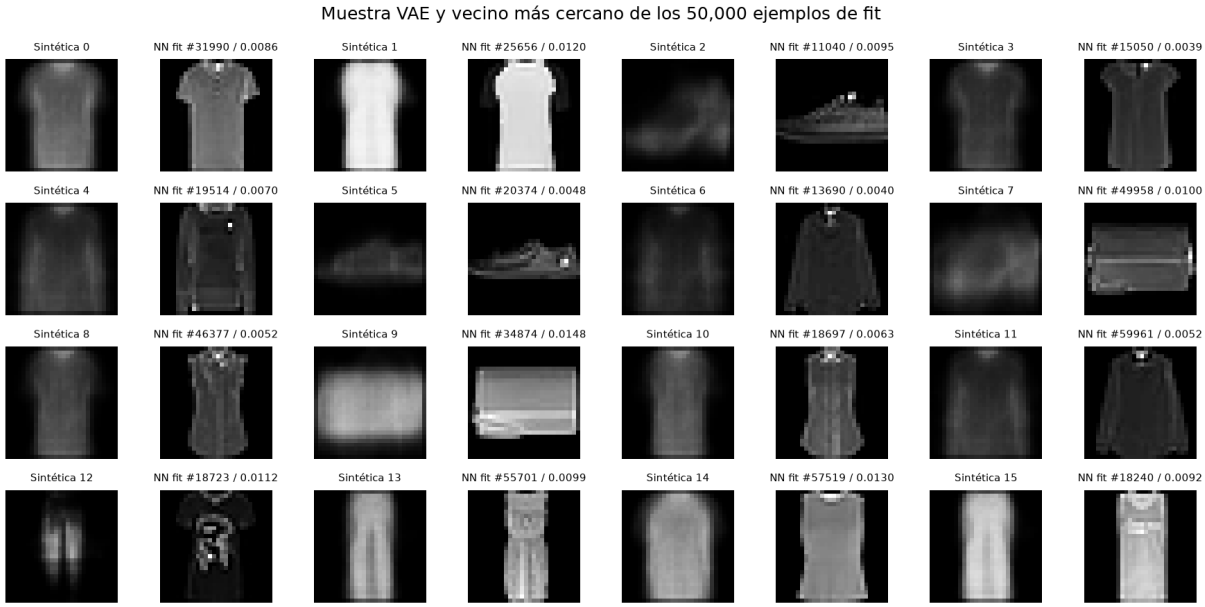


Arriba: AE entre los dos primeros ejemplos del panel (bolso/abrigo); abajo: VAE entre los dos primeros puntos del prior. Los extremos se fijaron por semilla, sin escoger por estética. Hay transición gradual en píxeles, con formas intermedias ambiguas.

El scatter de 2,000 ejemplos y la cuadrícula $[-2,2]^2$ están en notebook y reports. AE muestra escalas mayores; VAE concentra coordenadas más cerca del prior. KL>0 y muestras distintas no sugieren colapso total, pero no descartan colapso parcial. Los ejes no tienen significado semántico garantizado.

7. Vecinos cercanos y posible memorización

Cada una de 256 muestras se compara con los 50,000 ejemplos fit. Panel: primeras 16 muestras VAE y su vecino más cercano por MSE. Los índices originales y distancias se conservan en nearest_neighbors.csv.



MSE al vecino: media .01021, mínimo .00248; los 16 originales de prueba dan media .02284. No hubo distancia cero. Las salidas suavizadas pueden parecer prototipos; estos resultados no prueban copia ni garantizan privacidad, originalidad o ausencia de memorización.

8. Costo, pruebas y decisión de uso

AE usa 7.70 s y VAE 9.94 s en este equipo; la comparación no iguala épocas. Inferencia de 10,000: .246 s AE y .243 s VAE. Decoder para app: .963 MB. El notebook verifica hashes, recarga modelos y recalcula MSE sobre toda la prueba. Las 9 pruebas pasan, incluida Streamlit; la app solo hace inferencia y no entrena por visita.

Decisión: AE para reconstrucción didáctica y VAE para estudiar muestreo regularizado. No usar como catálogo comercial ni afirmar garantías de privacidad. Próximo experimento: igual presupuesto, varias semillas, mayor latente y convoluciones; evaluar diversidad y calidad perceptual y reservar una nueva prueba al ajustar modelos.

GAN enfrenta generador/discriminador y puede colapsar; transferencia reutiliza representaciones y no es por sí sola generativa. Ambos se comparan conceptualmente, sin entrenarlos en esta entrega.

9. IA, responsabilidad y referencias

Codex apoyó código, entrenamiento, pruebas y redacción. AI_USE_DECLARATION.md conserva prompt, verificaciones y correcciones; MODEL_CARD.md detalla límites. El estudiante debe revisar, reproducir y explicar la entrega. El formato sigue su documento de Unidad 02, Ejercicio 03.

Xiao, Rasul y Vollgraf (2017). Fashion-MNIST. arXiv:1708.07747. Kingma y Welling (2013). Auto-Encoding Variational Bayes. arXiv:1312.6114. Fuente oficial y licencia MIT. Tutorial oficial TensorFlow VAE.