U03 · Sistemas recomendadores

LAB08 y LAB09 · Evidencias del Ejercicio 05

Victor Manuel Perez Padilla | Matrícula: 100801946

Unidad 03 · Algoritmos y características generativas

Guía docente: Edwin Ramón José Nolasco

Repositorio del proyecto

1. Objetivo y estado de la entrega

Comparar popularidad, contenido, factorización e híbrido con datos reproducibles, evaluación temporal y análisis de costo. Se reutilizó el proyecto base del curso y un único entorno Python 3.12 con uv. La entrega incluye notebook ejecutado, código, pruebas, reportes, tarjetas y declaración de IA; el repositorio está publicado en GitHub.

2. Fuente, descarga y auditoría

MovieLens Latest Small, GroupLens Research, University of Minnesota. Es una edición de desarrollo que puede cambiar; no debe presentarse como benchmark archivado. Contiene ratings explícitos de 0.5 a 5 y usuarios anónimos con al menos 20 valoraciones. No incluye demografía.

Indicador	Resultado
Usuarios / películas / valoraciones	610 / 9,742 / 100,836
Películas con ratings / densidad	9,724 / 1.6968%
Periodo observado (UTC)	29-03-1996 a 24-09-2018
Entrenamiento / prueba	100,226 / 610 interacciones
Objetivos no vistos en entrenamiento	23; se conservan en el denominador
Empates temporales en el límite	94 usuarios; desempate por movieId

Se validaron columnas, nulos, claves, duplicados usuario-película, rango e incrementos de ratings y timestamps numéricos no negativos. Los originales no se modifican ni se redistribuyen. Condiciones: uso de investigación, reconocimiento obligatorio y permiso previo para uso comercial.

SHA-256 del ZIP original:

696d65a3dfceac7c45750ad32df2c259311949efec81f0f144fdfb91ebc9e436

Fecha de descarga UTC: 2026-10-23T10:46:44.692845+00:00. Fuente: reports/download_manifest.json y reports/audit.json.

3. Partición, modelos y métricas

Se retiene la última valoración de cada usuario elegible, ordenando por usuario, timestamp y movieId. Todos los métodos evalúan los mismos 610 usuarios sobre las 9,742 películas, excluyendo vistas. Medias, perfiles y factores usan entrenamiento; los metadatos de géneros se conocen para todo el catálogo.

Popularidad combina media del ítem y media global, con evidencia mínima igual al percentil 80 del conteo. Contenido usa TF-IDF y coseno; el perfil pondera ratings mediante max(rating-2.5, 0.1). MF aprende vectores latentes mediante SGD. El híbrido combina scores min-max: alpha·CF + (1-alpha)·contenido, sin prefiltrar candidatos por MF.

Se comparan 8 factores/4 épocas y 20/12, con semillas 17, 42 y 83 y alpha 0.25 y 0.75. MF usa learning rate .01 y regularización .05. Las dimensiones latentes no tienen significado humano garantizado.

4. Tabla principal de resultados

Modelo / f / épocas / alpha	RMSE*	HR@10 %	P@10 %	Cob. %	Seg.	MB
MF 8/4	1.1159	0.05	0.005	13.11	4.42	1.09
MF 20/12	1.0277	3.39	0.339	7.34	10.18	2.08
Contenido	-	0.16	0.016	7.94	0.79	1.08
Híbrido 8/4 / 0.25	1.1159	0.22	0.022	17.66	4.39	2.05
Híbrido 8/4 / 0.75	1.1159	0.22	0.022	17.14	4.40	2.05
Híbrido 20/12 / 0.25	1.0277	1.42	0.142	13.12	10.20	3.04
Híbrido 20/12 / 0.75	1.0277	3.28	0.328	9.56	10.24	3.04
Popularidad	1.1169	3.11	0.311	0.69	0.71	0.16

Fuente: reports/metrics.csv y reports/pareto.csv. Media de tres semillas para métodos estocásticos; deterministas una vez. HR mide recuperar la última interacción, incluso con rating bajo; con un único objetivo P@10=HR/10. Cobertura = unión de Top-10 / catálogo.

* El RMSE de popularidad usa media global, no su score de ranking. El del híbrido corresponde al componente MF: la mezcla normalizada no predice estrellas. Ítems desconocidos usan media global. No se mide RMSE de contenido.

MF 20/12 reduce RMSE a 1.0277 y obtiene HR 3.39%. Para los 363 objetivos con rating >=4, HR es 4.68% en popularidad, 4.96% en MF y 4.50% en híbrido .75. Aproximar ratings y acertar rankings son tareas distintas.

5. Tres consultas por contenido

Película consultada	Primera recomendación / géneros
Toy Story (1995)	Turbo (2013) / Adventure|Animation|Children|Comedy|Fantasy
Shawshank Redemption, The (1994)	Short Film About Killing, A (Krótki film o zabijaniu) (1988) / Crime|Drama
Exorcist, The (1973)	Darkness (2002) / Horror|Mystery

Ninguna consulta aparece en su Top-10. Géneros idénticos generan vectores y scores iguales. Repetir Crime/Drama en Shawshank ilustra sobre-especialización: similitud de metadatos no garantiza agrado. La interfaz muestra fuente, método y limitación.

6. Perfiles, cold start y estabilidad

Se seleccionan máximo y mínimo historial de entrenamiento, además del usuario sintético -1. Las listas excluyen vistos. El historial mínimo observado aún tiene 19 ratings: no representa un usuario con una o dos interacciones. El nuevo recibe popularidad no personalizada; no existe un objetivo observado para medir su precisión.

Perfil / usuario / historial	Primeras tres recomendaciones	Jaccard
amplio / 414 / 2697	12 Angry Men (1957); Life Is Beautiful (La Vita è bella) (1997); Intouchables (2011)	0.624
pequeno / 53 / 19	Annie Hall (1977); Godfather, The (1972); Punch-Drunk Love (2002)	0.037
nuevo / -1 / 0	Shawshank Redemption, The (1994); Godfather, The (1972); Fight Club (1999)	1.000

Ejemplo: híbrido 20/12, alpha .75, semilla 42. Jaccard compara los conjuntos Top-10 entre las tres parejas de semillas. Fuente: profile_recommendations.csv y profile_stability.csv. La menor estabilidad del perfil pequeño evidencia dependencia del ajuste; el fallback nuevo es compartido y estable.

Un ítem sin ratings de entrenamiento carece de vector aprendido: MF usa media global. Contenido puede usar sus géneros, si están disponibles. Esta política evita excluir los 23 objetivos nuevos y reportar métricas artificialmente favorables.

7. Híbrido, Pareto y costo computacional

Con 20/12, alpha .75 obtiene HR 3.28% frente a 1.42% con .25. El mayor peso colaborativo aumenta aciertos, pero reduce cobertura de 13.12% a 9.56%. Entre híbridos se elige .75 por ese intercambio observado; no se afirma superioridad universal.

Popularidad tarda 0.71 s y ocupa 0.16 MB; híbrido .75 tarda 10.24 s y ocupa 3.04 MB. Su ganancia media es 0.164 puntos porcentuales de HR, con 14.3 veces el tiempo; la cobertura pasa de 0.69% a 9.56%.

Pareto maximiza HR y cobertura y minimiza segundos y bytes. Una configuración está dominada si otra no empeora ninguno de esos objetivos y mejora al menos uno. Se usan medias entre semillas; pareto.csv y pareto.png registran la frontera. Híbrido 8/4/.75 queda dominado; varias alternativas permanecen en la frontera.

Tiempo = entrenamiento MF + ranking de 610 usuarios; excluye descarga, carga, TF-IDF compartido e I/O. Tamaño = estado serializado por método (ids, popularidad y contenido/MF cuando aplica), sin historial ni entorno. No se publican los objetos ni se miden energía o emisiones. Los tiempos tienen ruido local.

Decisión Green AI: mantener popularidad como referencia económica inicial; conservar el híbrido 20/12/.75 para estudiar personalización y exposición. La complejidad adicional necesita justificar su mejora marginal. Cobertura no equivale a diversidad individual ni satisfacción.

8. Pruebas, entorno y publicación

Entorno verificado: Python 3.12.14, uv y un único .venv. El notebook se ejecutó sin celdas con error. Las 16 pruebas locales incluyen contratos, errores, corte, exclusión de vistos, fallback, extremos del híbrido, métricas, Pareto y tres consultas Streamlit. GitHub Actions verifica el código sin redistribuir el dataset.

```
uv sync --locked
uv run python scripts/download_data.py
uv run python scripts/build_notebook.py
uv run python scripts/build_report.py
uv run streamlit run app/streamlit_app.py
```

README y requirements.txt documentan instalación y ejecución. Se usan rutas relativas; .venv, credenciales, temporales y datos quedan fuera de Git. El repositorio contiene src, tests, reports, notebook ejecutado, Dataset Card, System Card e informe. La plataforma local necesita acceso HTTPS a GroupLens.

9. Límites, riesgos y cierre interpretativo

Resultado principal: MF mejora aproximación de ratings y ranking frente a su versión pequeña, mientras el híbrido intercambia acierto y cobertura. Popularidad mantiene una utilidad cercana con mucho menor costo. El usuario frío recibe una lista útil como referencia, sin presentarla como personalizada.

Límites: 94 empates no permiten reconstruir el orden real; el corte por usuario admite futuro de otros usuarios y no controla disponibilidad temporal del catálogo. La comparación usa la misma prueba para elegir alpha, sin validación independiente. Las tres semillas comparten usuarios y partición: no demuestran significancia estadística.

Riesgos: concentración popular, repetición de géneros, sesgo de selección y retroalimentación de futuras recomendaciones. Sin demografía no pueden afirmarse resultados por grupos. Mitigación: medir exposición, novedad y diversidad por usuario; probar reranking diversificado y vigilar concentración.

Siguiente experimento: corte global estricto con disponibilidad de ítems, validación separada y prueba final intacta, múltiples positivos retenidos y evaluación de diversidad. La decisión actual es exploratoria; un Top-10 no es una verdad universal ni garantiza satisfacción.

10. Uso de IA y referencias

Codex apoyó implementación, depuración, experimentos, pruebas y redacción. docs/AI_USAGE.md registra el prompt, verificaciones y correcciones. El estudiante debe revisar, reproducir y explicar la entrega antes de presentarla. El formato de este informe sigue el documento personal de Unidad 02, Ejercicio 03.

GroupLens. MovieLens Latest Small: README y condiciones oficiales. Harper, F. M. y Konstan, J. A. (2015). The MovieLens Datasets: History and Context. ACM TiiS 5(4), artículo 19. doi:10.1145/2827872.