U04 · Impacto y equidad

LAB11 y LAB12 · Evidencias del Ejercicio 07

Victor Manuel Perez Padilla | Matrícula: 100801946

INF-8239 · Unidad 04 · Ética y roles en Ciencia de Datos
Guía docente: Edwin Ramón José Nolasco

Repositorio del proyecto · carpeta unidad04

1. Finalidad, interesados y proporcionalidad

Ensayar un DSS que prioriza evidencia para revisión humana, sin declarar emergencias, elegibilidad o intervenciones. El estudiante eligió como daño prioritario no omitir zonas que necesitan revisión. El caso es totalmente sintético: no representa personas, territorios ni estadísticas reales de República Dominicana.

Alternativa menos invasiva: revisar todos los casos por orden de recepción y lista de comprobación. El score no elimina casos. No se ha acreditado que el modelo sea necesario o proporcional para un uso real: se limita al laboratorio, con segundo operador para apelación y facultad humana de anular.

Interesado ficticio	Beneficio / daño y participación propuesta
Actor afectado	Acceso a revisión / omisión o estigma; apelación y segundo revisor
Operador	Evidencia / sobrecarga y automatización acrítica; registrar override
Responsable institucional	Trazabilidad / uso no autorizado; aprobar alcance o detener
Datos y privacidad	Contratos / proxies o identificadores; auditar y bloquear

2. Riesgos y NIST AI RMF

Riesgo prioritario	Prioridad*	Responsable y evidencia
R01: omitir positivos	12	Data Scientist; comparación de recall y falsos negativos
R02: ocultar incertidumbre interseccional	12	Validation Lead; conteos, soporte e intervalos
R06: sobrecarga por falsos positivos	9	Operations Lead; FPR y tasa de selección

*Escala ordinal propuesta 1–4 de probabilidad e impacto, producto del esquema docente; no es una probabilidad observada de daño. Se documentan 12 riesgos completos y residual alto en los prioritarios. La prioridad de daño fue confirmada por el estudiante; los restantes puntajes requieren su revisión, sin aprobación institucional ficticia.

GOVERN: propósito, RACI y límites. MAP: interesados y escenarios. MEASURE: auditoría y pruebas. MANAGE: puertas, apelación y rollback. El resumen identifica artefactos, sin equiparar su existencia con eficacia de controles organizativos.

3. Datos, corte temporal y comparación

Fixture docente de 640 casos: 353 positivos, 287 negativos; G1=396 y G2=244. Fechas inventadas de 2026, algunas futuras respecto de la entrega. Se conservan bytes y hash. Fit384 / validación96 / prueba160; los días empatados no se separan. El modelo y umbral se eligen en validación, no en prueba.

Predictores: zona, incidentes previos, infraestructura y exposición. Se excluyen id, fecha, target, protected_group y age_band. Se corrigió que age_band aparecía en los predictores de la base. Excluir sensibles no elimina proxies; zona permanece como riesgo.

Modelo / umbral	Accuracy	Recall	FPR	Selección
Dummy .5	0.5750	1.0000	1.0000	1.0000
Logística .5	0.7250	0.7283	0.2794	0.5375
Árbol .5	0.7063	0.7609	0.3676	0.5938
Logística .3 elegida	0.7375	0.9348	0.5294	0.7625

4. Grupos e intersecciones con soporte

Grupo	n / positivos / negativos	Recall (IC Wilson95%)	FPR (IC Wilson95%)
G1	101 / 49 / 52	0.939 [0.835, 0.979]	0.519 [0.387, 0.649]
G2	59 / 43 / 16	0.930 [0.814, 0.976]	0.562 [0.332, 0.769]

Intersección	n	Pos. / neg.	Soporte propuesto
G1 | 18-29	18	4 / 14	Insuficiente
G1 | 30-44	24	16 / 8	Insuficiente
G1 | 45-59	35	17 / 18	Sí
G1 | 60+	24	12 / 12	Insuficiente
G2 | 18-29	11	8 / 3	Insuficiente
G2 | 30-44	14	12 / 2	Insuficiente
G2 | 45-59	8	6 / 2	Insuficiente
G2 | 60+	26	17 / 9	Insuficiente

Soporte: n>=30 y >=10 por clase, propuesta académica. Solo 1/8 cumple; no se calcula brecha robusta entre una sola intersección. Se muestra toda la evidencia, sin convertir desconocidos en cero. Wilson supone observaciones independientes, sin ajuste por múltiples comparaciones o tiempo.

5. Mitigación, trade-offs y Green AI

Logística .3 fue elegida en validación al priorizar recall. En prueba reduce falsos negativos de 25 a 6 entre 92 positivos, pero aumenta falsos positivos de 19 a 36 entre 68 negativos; la revisión pasa de 86 a 122 de 160 casos. No se midió capacidad real de atención. El Dummy alerta todo: recall1 y brecha0 no equivalen a justicia.

Alternativa	Fit (s)	KiB joblib	ms/registro*
Dummy	0.02984	2.946	0.0257
Logística .5	0.00559	3.282	0.0251
Árbol .5	0.00407	6.995	0.0233
Logística .3	0.00559	3.282	0.0211

*Tiempo batch dividido por 160, no latencia p95 de una petición. Tiempos pequeños y locales con ruido; no se midió energía ni CO2. El árbol es mayor y su brecha FPR .2548 a .5 supera .16; su complejidad no resuelve el problema. No se justifica el modelo más grande por tamaño.

6. Decisión, límites y condición de retiro

LIMITAR al laboratorio y mantener REVIEW para despliegue. Los grupos principales con logística .3 tienen brechas recall .0085 y FPR .0433, pero la evidencia interseccional es insuficiente. Las puertas no fallan por una brecha interseccional excesiva medida, sino porque no puede estimarse con soporte suficiente. Diferencias de tasas no prueban discriminación causal.

STOP ante identificadores, contrato inválido o uso fuera de alcance; no descartar casos por score. El simulacro deja MANUAL_ONLY. Antes de otro uso: revisar finalidad y base jurídica si hay datos personales, participación real, capacidad de revisión, soporte y etiquetas; obtener nueva prueba si se ajusta el modelo. Responsable final: Institutional Owner, rol simulado.

7. Normativa, pruebas y uso de IA

Ley172-13: obligación jurídica a analizar para datos personales según alcance; este fixture no trata titulares reales. NIST AI RMF1.0 y principios OCDE: marcos de orientación, no leyes dominicanas ni fuente de tolerancias numéricas. Revisión humana, soporte y retención: propuestas éticas y políticas del laboratorio, no plazos legales. No se certifica cumplimiento por pasar tests.

Pruebas ejecutadas: 24 passed in 3.25s. Python 3.12.14, Fairlearn 0.12.0. Codex apoyó código y redacción; el estudiante debe revisar valores propuestos y defender conclusiones. No se inventan firmas ni participación. Fuentes y prompts: NORMATIVE_FRAMEWORK.md y AI_USE_DECLARATION.md.

Referencias: NIST AI RMF1.0; OCDE IA; Fairlearn; Ley172-13, fuente oficial.